Raport - pracownia nr 5

Autor:

Szymon Koper (*247985*)

> sz.koper@gmail.com

Repozytorium:

Kod źródłowy znajduje się tutaj:

> https://github.com/sakydpozrux/AI-course/tree/master/5-markov-decision-processes/mdp-ruby

Część 1 - Iteracja wartości

> Napisz program rozwiązujący dyskretne problemy MDP opisanego typu metodą iteracji wartości lub iteracji polityki.
> W tym celu opracuj opis formalny zagadnienia, tak aby specyfikację konkretnej instancji zagadnienia można było oddzielić od programu i umieścić w oddzielnym pliku. Dotyczy to geometrii świata (NxM), modelu niepewności ruchów (a,b), funkcji nagrody (r i indywidualne wartości), i współczynnika dyskontowania (d).
>
> Uwaga: załączony rysunek świata agenta jest jedynie przykładowy. Program powinien być w stanie rozwiązać zadanie dla dowolnego świata, zgodnego z powyższą specyfikacją.
>
> Przez rejestrowanie przez program wyników częściowych, zaimplementuj analizę zbieżności algorytmu tworząc wykres wartości użyteczności stanów programem Gnuplot. Załącz zarówno wynikowy wykres, jak i opracowany komplet poleceń Gnuplota, oraz pliki danych, pozwalające wygenerować ten wykres dla każdej instancji problemu.

1.

> Oblicz rozwiązanie zagadnienia 4x3 przedstawionego na wykładzie. Porównaj wyniki. W raporcie podaj komplet otrzymanych użyteczności stanów, politykę, oraz wykres zbieżności. A następnie porzuć ten przykład (był tylko na rozgrzewkę).

Dane wejściowe:

dana	wartość
a	0.8
b	0.1
reward	0.04
discount	1.0
epsilon	0.05

Wejście - pola i nagrody:

```
O O O G
O F O G
S O O O

-0.04 -0.04 -0.04 1.0
-0.04 -0.04 -0.04 -1.0
-0.04 -0.04 -0.04 -0.04
```

Obliczone użyteczności:

```
   0.81    0.87    0.92    1.00
   0.76    0.00    0.66   -1.00
   0.70    0.64    0.59    0.36
```

Znaleziona polityka:

```
>>>G
^F^G
^<<<
```

Wykres użyteczności:

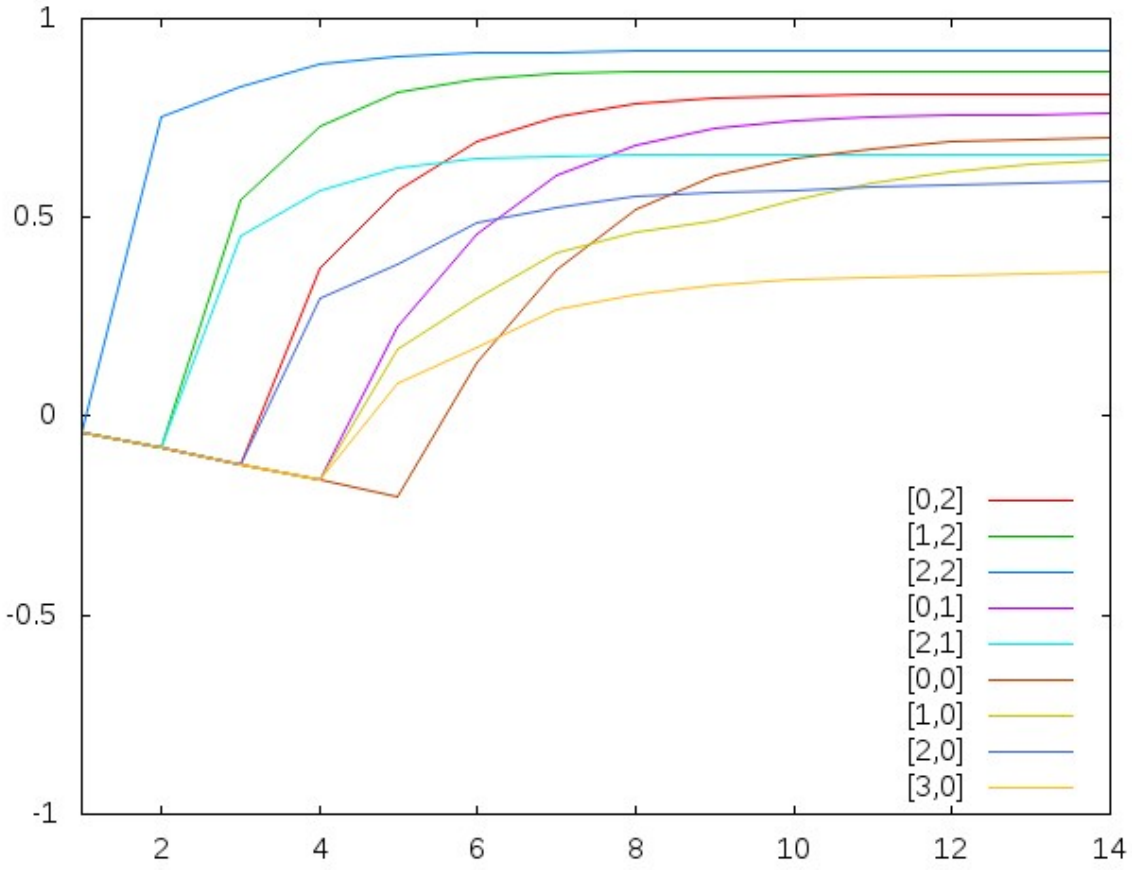

Wnioski:

Algorytm iteracji wartości zbiega po 14 iteracjach. Wyliczona polityka wygląda bardzo sensownie i jest podobna do polityki przedstawionej na wykładzie.

2.

Znajdź rozwiązanie zagadnienia pokazanego na obrazku (N=4, M=4), przyjmując model niepewności ruchów dokładnie taki sam jak w przykładach omawianych na wykładzie (a=0.8, b=0.1), i współczynnika dyskontowania d=0.99. Funkcja nagrody wynosi +100 dla stanów terminalnych, -20 dla stanów specjalnych, i r=-1 dla zwykłych stanów. Jako kryterium stopu algorytmu możesz przyjąć zejście wszystkich różnic funkcji wartości między kolejnymi iteracjami poniżej 0.01. Podaj komplet wartości użyteczności, politykę optymalną, i wykres zbieżności.

Dane wejściowe:

dana	wartość
a	0.8
b	0.1
reward	1.0
discount	0.99
epsilon	0.05

Wejście - pola i nagrody:

```
0 0 0 0
0 0 0 0
0 0 B 0
S 0 F G

-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -20.0 -1.0
-1.0 -1.0 -1.0 100.0
```

Obliczone użyteczności:

```
  81.94   84.26   86.59   88.88
  81.73   84.27   87.06   91.55
  79.59   80.60   70.47   94.54
  77.45   78.25    0.00  100.00
```

Znaleziona polityka:

```
>>>v
>>>v
^^>v
^^FG
```

Wykres użyteczności:

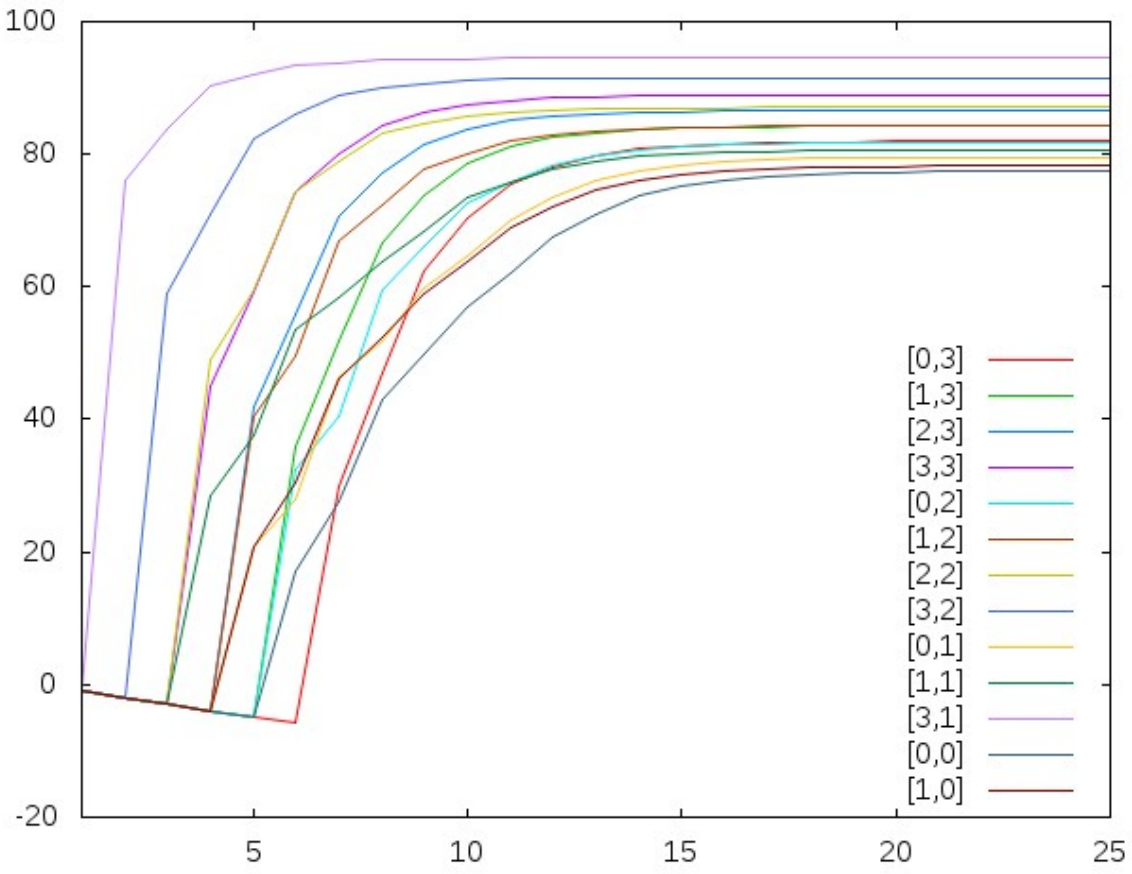

Wnioski:

Algorytm iteracji wartości zbiega po 25 iteracjach. Tutaj również rozwiązanie znalezione przez algorytm iteracji wartości wygląda sensownie.

3.

> Zmień funkcję nagrody dla stanów normalnych, specjalnych, i/lub terminalnych (względem podstawowej wersji zadania) w taki sposób, aby skutkowało to istotną zmianą polityki optymalnej. Przedstaw komplet rozwiązań dla zmienionego zadania (użyteczności i politykę). Wyjaśnij uzyskane wyniki.

Dane wejściowe:

dana	wartość
a	0.8

b	0.1
reward	1.0
discount	0.9
epsilon	0.05

Wejście - pola i nagrody:

```
O O O O
O O O O
O O B O
S O F G

-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 200.0 -1.0
-1.0 -1.0 -1.0 100.0
```

Obliczone użyteczności:

```
 887.12  997.90 1111.33 1002.59
 997.80 1137.57 1294.85 1129.65
1110.17 1294.10 1516.40 1201.47
 995.86 1121.29    0.00  100.00
```

Znaleziona polityka:

```
>vvv
>>v<
>>v<
>^FG
```

Wykres użyteczności:

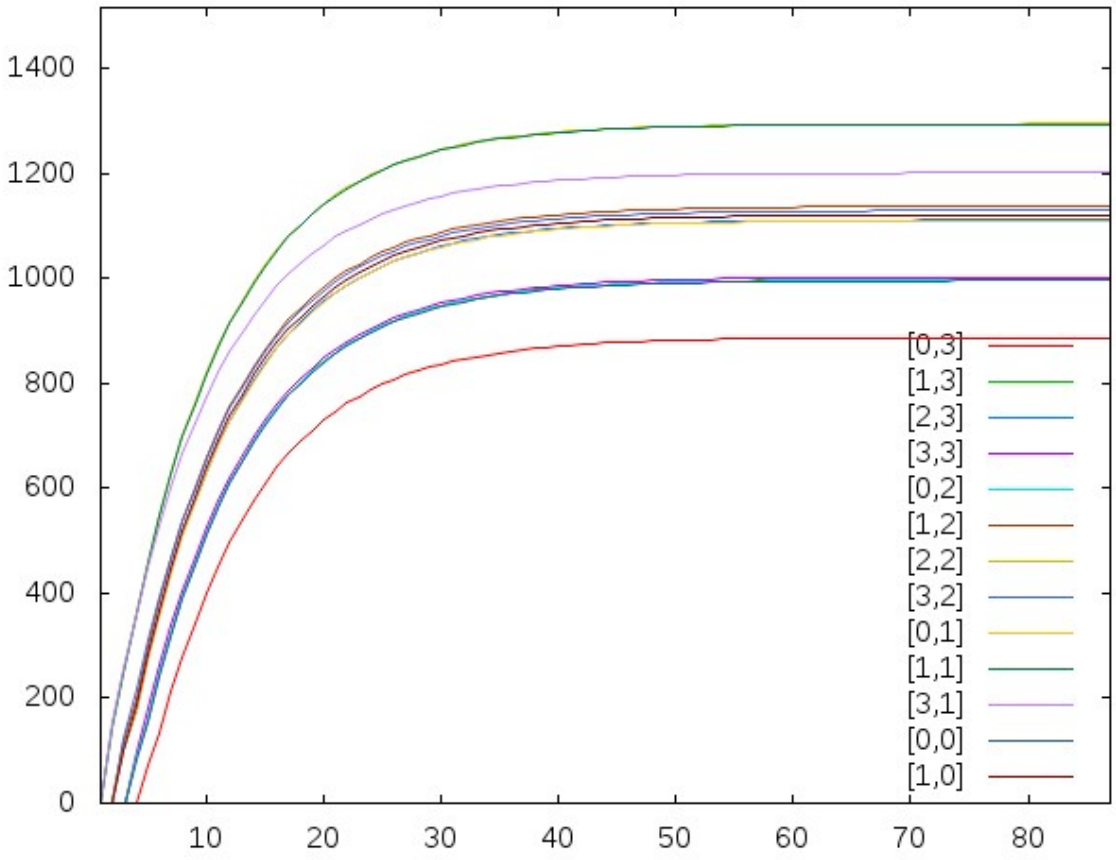

Wnioski:

Pole specjalne ma nagrodę dużo wyższą (wartość 200) niż stan terminalny (wartość 100), przez co algorytm dąży do jak najdłuższego pozostania na polu specjalnym i kumulację nagrody, poprzez próby wejścia na sąsiednią ścianę. To jest też powodem tak dużej liczby iteracji, w liczbie 87.

4.

> Zmień model niepewności ruchów (względem podstawowej wersji zadania) w taki sposób, aby skutkowało to zmianą polityki optymalnej. Przedstaw komplet rozwiązań dla zmienionego zadania (użyteczności i politykę). Wyjaśnij uzyskane wyniki.

Dane wejściowe:

dana	wartość

a	0.5
b	0.25
reward	1.0
discount	0.99
epsilon	0.05

Wejście - pola i nagrody:

```
O O O O
O O O O
O O B O
S O F G

-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -20.0 -1.0
-1.0 -1.0 -1.0 100.0
```

Obliczone użyteczności:

```
  58.10   62.02   66.22   70.04
  56.67   60.18   65.33   75.39
  53.87   54.52   50.14   83.98
  50.96   51.29    0.00  100.00
```

Znaleziona polityka:

```
>>>v
^>^v
^^>>
^^FG
```

Wykres użyteczności:

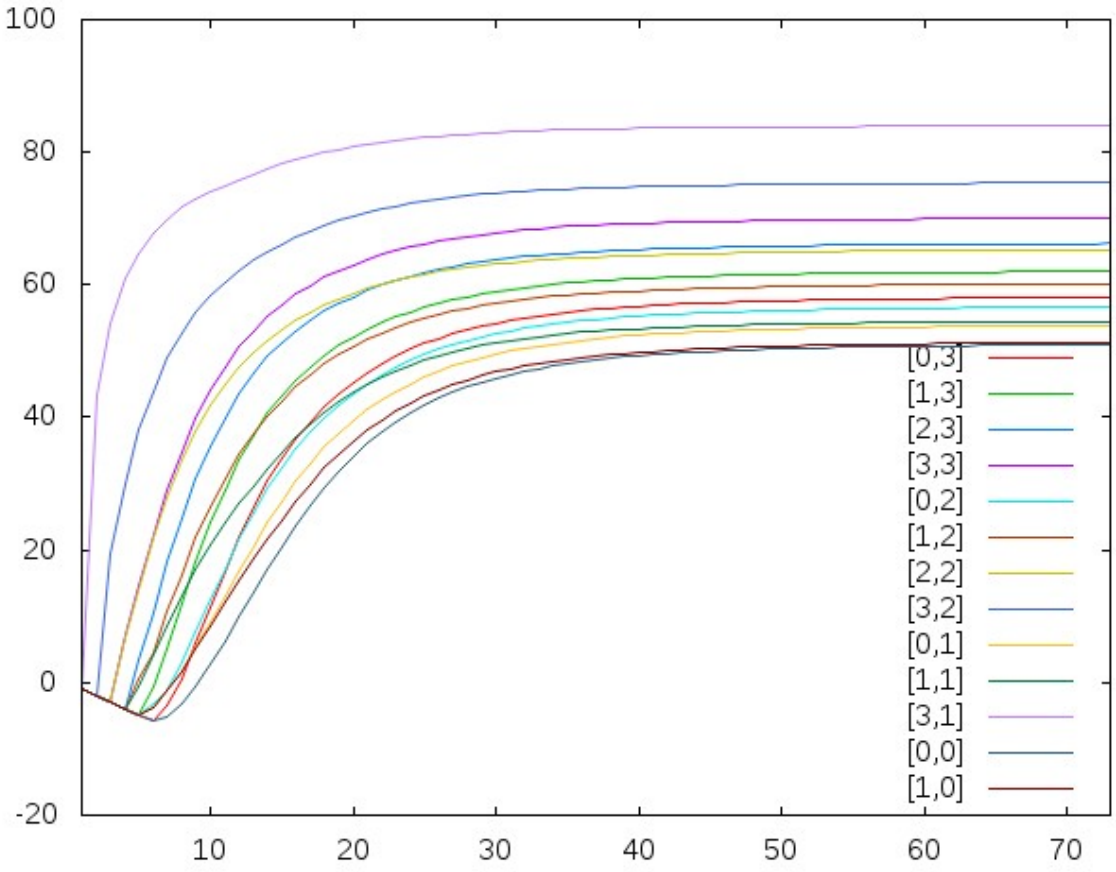

Wnioski:

Zmiany te skutkują wyraźnie zauważalną zmianą polityki znalezionej przez algorytm iteracji wartości. Algorytm stara się uniknąć przechodzenia przez pole specjalne o wysokiej karze Ciekawe jest to, że algorytm stara się przechodzić w bezpiecznej odległości od pola specjalnego, czyli nie idzie najkrótszą ścieżką. W polu (4,2) żeby nie ryzykować wejścia na pole specjalne, polityka sugeruje próbę wejścia na ścianę po prawej stronie, co skutkuje szansą 50% na pozostanie w tym samym polu, i po 25% na przejście na pole wyżej lub przejście do stanu terminalnego. Algorytm zbiega po 73 iteracjach.

5.

> Zmień współczynnik przeceniania (względem podstawowej wersji zadania) w taki sposób, aby skutkowało to zmianą polityki optymalnej. Przedstaw komplet rozwiązań dla zmienionego zadania (użyteczności i politykę). Wyjaśnij uzyskane wyniki.

Dane wejściowe:

dana	wartość
a	0.8
b	0.1
reward	1.0
discount	0.6
epsilon	0.05

Wejście - pola i nagrody:

```
O O O O
O O O O
O O B O
S O F G

-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -20.0 -1.0
-1.0 -1.0 -1.0 100.0
```

Obliczone użyteczności:

```
   0.20    2.30    5.97   12.28
   1.37    4.94   11.86   25.39
  -0.14    1.77    5.18   50.33
  -1.15   -0.23    0.00  100.00
```

Znaleziona polityka:

```
>>>v
>>>v
>>>v
^^FG
```

Wykres użyteczności:

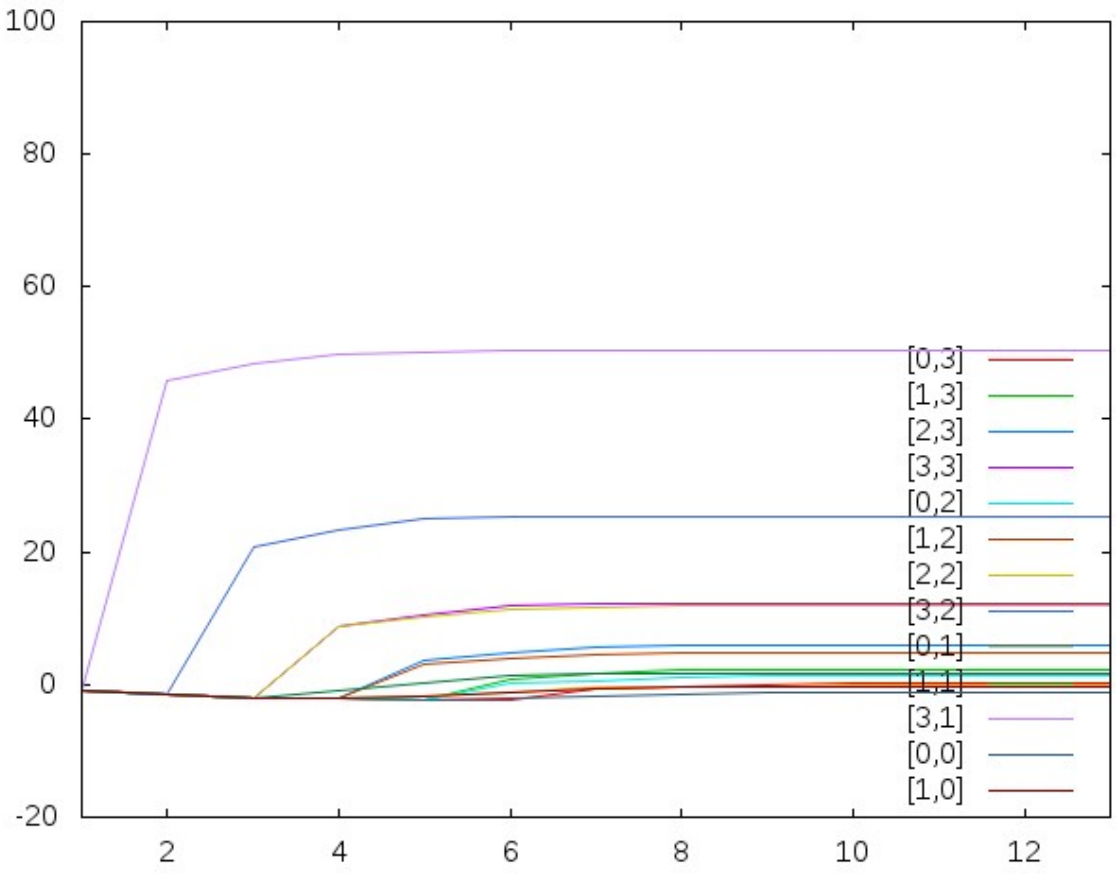

Wnioski:

W stosunku do danych z zadania 3 zmieniłem tutaj współczynnik dyskontowania na 0,6. Jest to wartość na tyle mała, że algorytm nie zdążył wyliczyć poprawnych wartości (zbiegł zbyt szybko, w 13 iteracjach) i sugeruje przejście przez niekorzystny stan specjalny. Wygląda na to, że algorytm przy tych danych sugeruje użycie najkrótszej ścieżki, ale niekoniecznie najtańszej.

Część 2 - Q-Learning

> W drugiej części zadania, zaimplementuj obliczanie optymalnej polityki agenta metodą Q-learning z eksploracją. Należy przyjąć te same parametry co w pierwszej części zadania. Jednak model ruchów i wartości nagrody są tu nieznane agentowi. Muszą one być użyte dla wygenerowania przebiegów uczących, zatem program musi składać się z dwóch części: agenta, który uczy się środowiska z przebiegów uczących, i symulatora, który te przebiegi uczące generuje. Za każdym razem wygeneruj 10000 przebiegów uczących zaczynając ze stanu startowego do osiągnięcia stanu terminalnego. Rozwiąż instancję problemu dla świata na załączonym rysunku z

ustawieniami: a=0.9, b=0.05, d=0.99 i współczynnikiem uczenia $\alpha = 1/N(s,a)$ gdzie N(s,a) jest liczbą razy jaką akcja a została wybrana w stanie s w dotychczasowych przebiegach.

Uwzględnij dwie strategie eksploracji, z $\epsilon = 0.05 i \epsilon = 0.2$. To znaczy, optymalny ruch (eksploatacja) powinien zostać wybrany z prawdopodobieństwem ϵ, a z prawdopodobieństwem $1 - \epsilon$ ruch wybrany losowo (eksploracja).

Przeanalizuj wpływ wartości ϵ na zbieżność procesu Q-learning, oraz na uzyskaną w jego wyniku politykę.

Oba badane przypadki mają identyczną planszę i nagrody poszczególnych pól:

```
0 0 0 0
0 0 0 0
0 0 B 0
S 0 F G

-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -1.0 -1.0
-1.0 -1.0 -20.0 -1.0
-1.0 -1.0 -1.0 100.0
```

1.

Dane wejściowe:

dana	wartość
a	0.9
b	0.05
reward	1.0
discount	0.99
epsilon	**0.05**

Obliczone użyteczności:

```
  33.17   83.15   87.93   92.50
```

```
  78.09   90.08   93.50   95.92
  74.78   84.74   71.49   97.99
  65.86   76.73    0.00  100.00
```

Znaleziona polityka:

```
vvvv
>>>v
>^^v
>^FG
```

Wykres użyteczności:

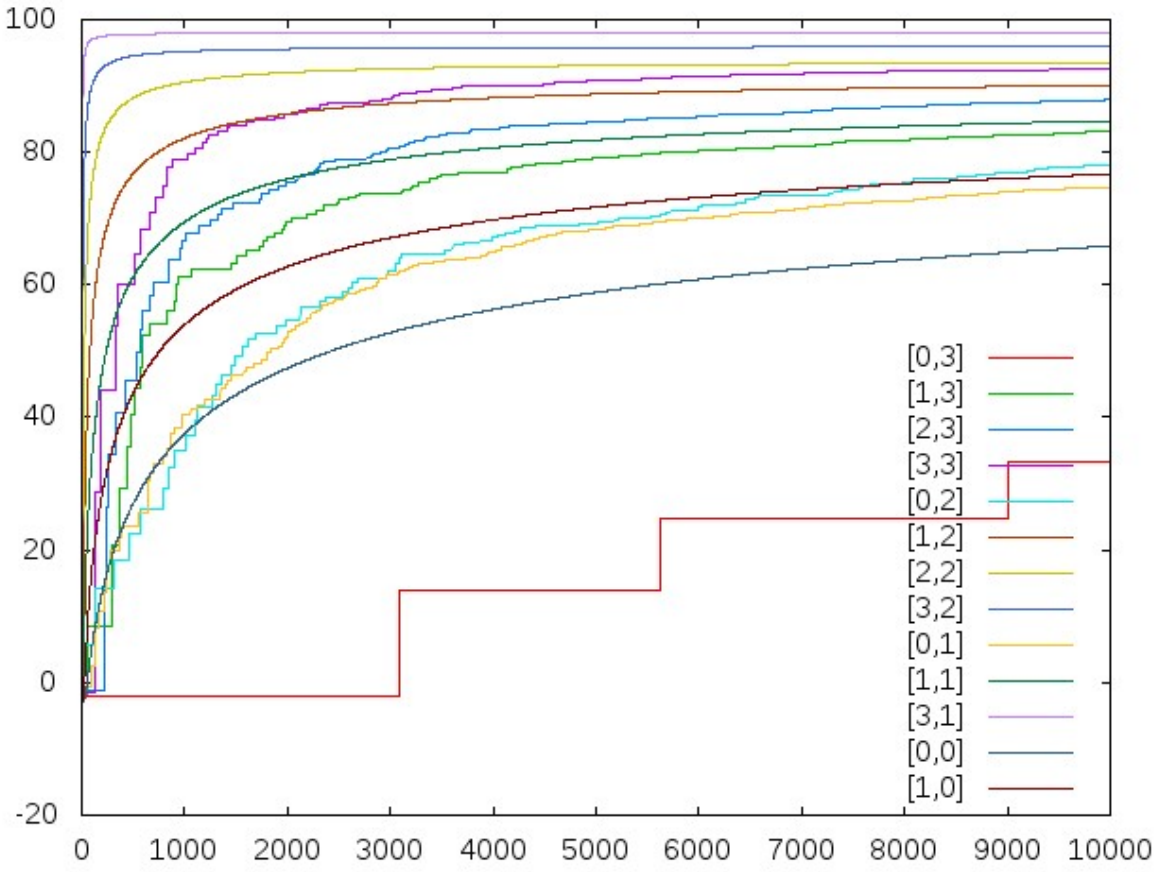

2.

Dane wejściowe:

dana	wartość

a	0.9
b	0.05
reward	1.0
discount	0.99
epsilon	**0.2**

Obliczone użyteczności:

```
  85.76   87.81   89.86   91.93
  86.48   88.73   91.05   94.20
  84.49   85.91   74.21   96.55
  82.51   83.78    0.00  100.00
```

Znaleziona polityka:

```
>>>v
>>>v
^^>v
^^FG
```

Wykres użyteczności:

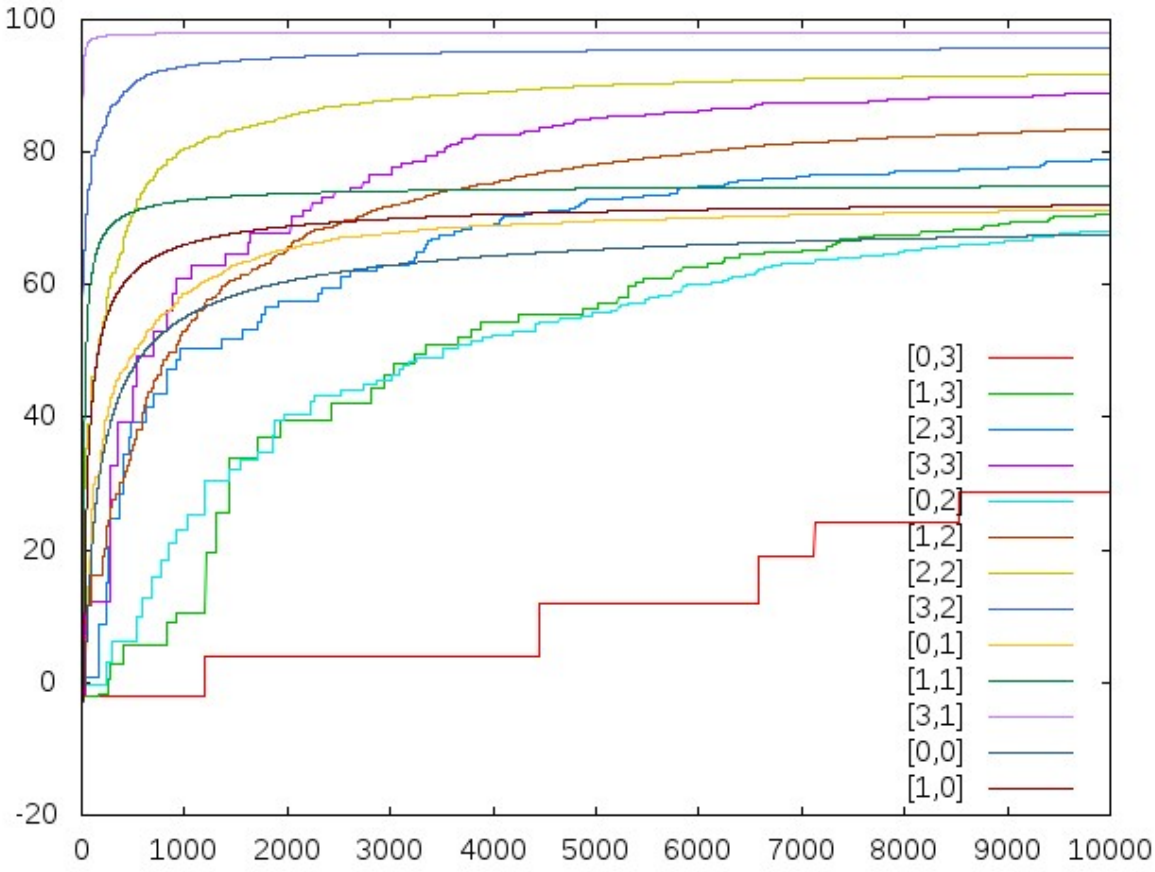

Wnioski z części 2:

Wartość epsilona ustawiona na 0.05, skutkowuje algorytmem odważniej eksplorującym planszę, ale mniej chętnie korzystającym z już posiadanej wiedzy, czyli podążania ścieżką uznawaną za aktualnie optymalną.
W otrzymanych politykach jest widoczna znaczna różnica.